


# Prepoznavanje znakovnog jezika pomoću tenzora

Petra Sočo, Jelena Zaninović

8. ožujka 2021.

## Prepoznavanje gesti rukama

- Računalno prepoznavanje gesti rukama može zamijeniti direktni kontakt s ekranima u javnosti ili u prostorima koji se pokušavaju držati sterilnima (npr. operacijske sale)
- To bi omogućilo sigurniju, ali i intuitivniju interakciju ljudi s računalima (smart uređaji, AR, VR).




- Jedna od zanimljivijih i korisnijih primjena je kod prepoznavanja znakovnog jezika; naime, računala bi mogla automatski transkribirati znakove u tekst ili govor, što bi moglo olakšati i ubrzati komunikaciju s osobama koje ga koriste.




- Kako bi program što bolje funkcionirao u praksi, moramo razmisliti na koji će način primati informacije - u našem slučaju slike ruku. Osobi nije praktično gestikulirati iz jedne fiksne poze pa ima smisla prilagoditi program da prepozna znakove iz različitih kuteva.
- Kad bi računalo (kamera) radilo izvan ambijenta s konzistentnim, umjetnim osvjetljenjem, bilo bi poželjno da mu točnost ne ovisi o dobu dana.

# Fotografije

- Fotografije su slikane iz 5 različitih kuteva - od  $45^\circ$  slijeva do  $45^\circ$  zdesna. Fotoaparat je bio u razini prsa osobe i paralelan s podom.





Slika: Slovo P iz 5 različitih kuteva

- Od 26 znakova uspješno samo slikale 24 (nedostaju nam slova 'M' i 'N') te smo u konačnici dobile 120 slika.
- Rezolucija svake slike je  $25 \times 25$  piksela.

## Prepoznavanje ruke na slici

- Piksele dijelimo na 2 klastera: "boja kože" i "ostalo"
- YCbCr model boja osmišljen je tako da Y prati svjetlinu slike, a Cb i Cr informacije o bojama (konkretno, plavoj i crvenoj)
- Sliku iz češće korištenog RGB-a konvertiramo u YCbCr preko sljedeće formule

$$\begin{bmatrix} Y \\ C_b \\ C_r \end{bmatrix} = \begin{bmatrix} 16 \\ 128 \\ 128 \end{bmatrix} + \begin{bmatrix} 65.481 & 128.553 & 24.966 \\ -37.797 & -74.203 & 112 \\ 112 & -93.786 & -18.214 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

- Iz RGB slika, zbog jasnije teksture, dobile smo greyscale slike, a iz YCbCr slika, gdje je razlika između ruke i podloge značajnija, dobile smo binary slike.
- U ovom smo koraku koristile Octave Forge 'Image' paket: konkretno, funkcije **rgb2gray** i **im2bw**.
- Napomena: **im2bw** koristi određeni "threshold" nad kojim nemamo kontrolu, što može utjecati na konačnu sliku.





Slika: Slovo A u različitim modelima boja




## Definicija

Ako je polje  $\mathcal{A}$  određeno s  $N$  indeksa, kažemo da je

$\mathcal{A} \in \mathbb{R}^{I_1 \times I_2 \times \dots \times I_N}$  **tenzor reda  $N$**  nad  $\mathbb{R}$ ,  $\mathcal{A} = (x_{i_1 i_2 \dots i_{n-1} i_n i_{n+1} \dots i_N})$ ,  
 $i_1 = 1, \dots, I_1; \dots; i_N = 1, \dots, I_N$ .

## Definicija

Neka je  $\mathcal{A} \in \mathbb{R}^{I_1 \times I_2 \times \dots \times I_N}$  tenzor.  $I_n$ -dimenzionalni vektor dobiven t.d. fiksiramo svaki indeks osim indeksa  $i_n$  zovemo **nit u modu  $n$** .



## Definicija

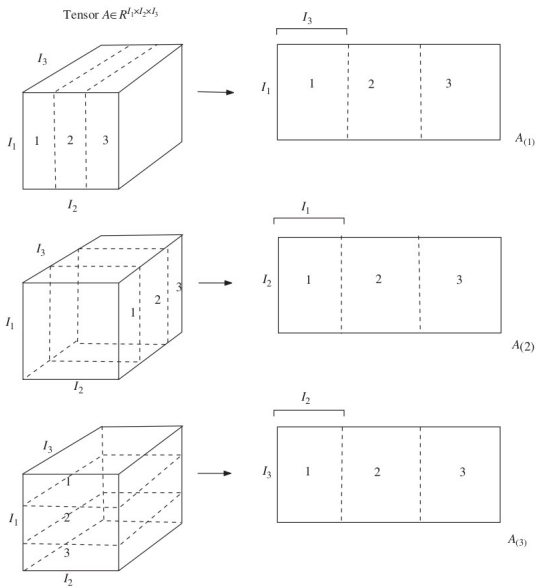
Neka je  $\mathcal{A} \in \mathbb{R}^{I_1 \times I_2 \times \dots \times I_N}$  i neka je  $\mathbf{U} \in \mathbb{R}^{J_n \times I_n}$ . **Produkt u modu n** tenzora  $\mathcal{A}$  i matrice  $\mathbf{U}$ , s oznakom  $\mathcal{A} \times_n \mathbf{U}$ , je  $(I_1 \times I_2 \times \dots \times I_{n-1} \times J_n \times I_{n+1} \times \dots \times I_N)$ -dimenzionalni tenzor zadan s

$$(\mathcal{A} \times_n \mathbf{U})_{i_1 i_2 \dots i_{n-1} j_n i_{n+1} \dots i_N} := \sum_{i_n} a_{i_1 i_2 \dots i_{n-1} i_n i_{n+1} \dots i_N} u_{j_n i_n}.$$

- Produkt u modu n možemo izraziti i na sljedeći način

$$(\mathcal{A} \times_n \mathbf{U})_{(n)} = \mathbf{U} \cdot \mathbf{A}_{(n)},$$

gdje smo s  $\mathbf{A}_{(n)}$  označili **matricizaciju** od  $\mathcal{A}$  u **n-tom modu**



## Teorem

Neka je  $\mathcal{A} \in \mathbb{R}^{I_1 \times I_2 \times \dots \times I_N}$ . Za  $A \in \mathbb{R}^{I_m \times J_m}$ ,  $B \in \mathbb{R}^{I_n \times J_n}$ ,  $m \neq n$  vrijedi

$$\mathcal{A} \times_m A \times_n B = (\mathcal{A} \times_m A) \times_n B = (\mathcal{A} \times_n B) \times_m A.$$

## Teorem

Neka je  $\mathcal{A} \in \mathbb{R}^{I \times m \times n}$ . Tenzor  $\mathcal{A}$  možemo zapisati kao

$$\mathcal{A} = \mathcal{S} \times_1 \mathbf{U}^{(1)} \times_2 \mathbf{U}^{(2)} \times_3 \mathbf{U}^{(3)}$$

gdje su  $\mathbf{U}_1 \in \mathbb{R}^{I \times I}$ ,  $\mathbf{U}_2 \in \mathbb{R}^{m \times m}$ ,  $\mathbf{U}_3 \in \mathbb{R}^{n \times n}$  ortonormalne matrice, a jezgri tenzor  $\mathcal{S}$  je istih dimenzija kao  $\mathcal{A}$  te ima svojstvo potpune ortogonalnosti. Vrijedi i da je

$$\mathcal{S} = \mathcal{A} \times_1 (\mathbf{U}^{(1)})^T \times_2 (\mathbf{U}^{(2)})^T \times_3 (\mathbf{U}^{(3)})^T.$$

## Definicija

*Neka je  $A \in \mathbb{R}^{m \times n}$ . Kažemo da je matrica  $A^+ \in \mathbb{R}^{n \times m}$*

*Moore-Penroseov pseudoinverz matrice  $A$  ako zadovoljava sljedeće uvjete:*

- $AA^+A = A$
- $A^+AA^+ = A^+$
- $(AA^+)^* = AA^+$
- $(A^+A)^* = A^+A$

## Reprezentacija podataka tenzorom

- $l_l, l_v$  i  $l_{pix}$  ... broj slova, perspektiva i piksela.
- Ulazni podaci ... tenzor oblika  $\mathcal{A} \in \mathbb{R}^{l_l \times l_v \times l_{pix}}$ .
- Informacije o slovima i perspektivama faktoriziramo pomoću HOSVD-a

$$\mathcal{A} = \mathcal{S} \times_1 \mathbf{U}_l \times_2 \mathbf{U}_v \times_3 \mathbf{U}_{pix}, \quad (1)$$

gdje su  $\mathbf{U}_l, \mathbf{U}_v$  i  $\mathbf{U}_{pix}$  ortogonalne matrice reda  $l_l, l_v$  i  $l_{pix}$ , a  $\mathcal{S} \in \mathbb{R}^{l_l \times l_v \times l_{pix}}$  **jezgreni tenzor**.

- Za sliku slova  $i$  u pogledu  $j$  ( $i = 1, \dots, l_l, j = 1, \dots, l_v$ ) imamo

$$\mathcal{A}^{(i,j)} = \mathcal{S} \times_1 \mathbf{u}_i \times_2 \mathbf{u}_j \times_3 \mathbf{U}_{pix}$$

gdje su  $\mathbf{u}_i$  i  $\mathbf{u}_j$  redom retci matrica  $\mathbf{U}_l$  i  $\mathbf{U}_v$ ,  $\mathcal{A}^{(i,j)} \in \mathbb{R}^{1 \times 1 \times l_{pix}}$ .

# Prepoznavanje znakovnog jezika tenzorom

- Naći najbolju aproksimaciju među već dostupnim podacima
- Testna slika  $\mathcal{A}_{test} \in \mathbb{R}^{1 \times 1 \times I_{pix}}$  ima rastav

$$\mathcal{A}_{test} = \mathcal{S} \times_1 \mathbf{u}_i \times_2 \mathbf{u}_j \times_3 \mathbf{U}_{pix}$$

za neke nepoznate  $\mathbf{u}_i$  i  $\mathbf{u}_j$ .

- Problem glasi

$$\arg \min_{\mathbf{u}_i, \mathbf{u}_j} \|\mathcal{A}_{test} - \mathcal{S} \times_1 \mathbf{u}_i \times_2 \mathbf{u}_j \times_3 \mathbf{U}_{pix}\|_2.$$

- Rezultat: aproksimacije vektora  $\mathbf{u}_i$  i  $\mathbf{u}_j$
- Računamo tako da  $\mathbf{u}_j$  budu generirani iz konačnog skupa.



Konkretno, neka je  $\mathbf{u}_j \in \{\mathbf{U}_v(k, 1 : l_v) : k = 1, \dots, l_v\}$ . Problem sada glasi:

$$\arg \min_{\mathbf{u}_i} \|\mathcal{A}_{test} - \mathcal{S} \times_1 \mathbf{u}_i \times_2 \mathbf{u}_j \times_3 \mathbf{U}_{pix}\|_2 \quad (2)$$

Korištenjem svojstava množenja tenzora i matrice u modu 1:

$$\arg \min_{\mathbf{u}_i} \|\mathcal{A}_{test} - \mathbf{u}_i \times (\mathcal{S} \times_2 \mathbf{u}_j \times_3 \mathbf{U}_{pix})_{(1)}\|_2 \quad (3)$$

pa imamo kandidata za aproksimaciju:

$$\mathbf{u}_i = \mathcal{A}_{test} \times (\mathcal{S} \times_2 \mathbf{u}_j \times_3 \mathbf{U}_{pix})_{(1)}^+ \quad (4)$$

gdje s '+' označavamo Moore-Penroseov pseudoinverz.

- $l_v$  kandidata za aproksimaciju  $\{\mathbf{u}_i : i = 1, \dots, l_v\}$  koje uspoređujemo sa retcima matrice  $\mathbf{U}_l \rightarrow$  tražimo  $k \in \{1, \dots, l_l\}$  koji minimizira sljedeći izraz

$$\|\mathbf{u}_i - \mathbf{U}_l(k, 1 : l_l)\|_2.$$

- Pomoću kosinusa kuta 2 vektora  $\mathbf{u}_i$  i  $\mathbf{U}_l(k, 1 : l_l)$  možemo računati:

$$\arg \max_{i,k} \frac{\langle \mathbf{u}_i, \mathbf{U}_l(k, 1 : l_l) \rangle}{\|\mathbf{u}_i\| \|\mathbf{U}_l(k, 1 : l_l)\|} \quad (5)$$

# ALGORITAM

IN :  $\mathcal{A}_{test}$

- Za svaki  $\mathbf{u}_j \in \{\mathbf{U}_v(k, 1 : l_v) : k = 1, \dots, l_v\}$  izračunaj

$$\mathbf{u}_i = \mathcal{A}_{test} \times (\mathcal{S} \times_2 \mathbf{u}_j \times_3 \mathbf{U}_{pix})_{(1)}^+$$

- Nađi  $k \in \{1, \dots, l_l\}$  koji minimizira sljedeći izraz

$$\|\mathbf{u}_i - \mathbf{U}_l(k, 1 : l_l)\|_2.$$

OUT:  $k \in \{1, \dots, l_l\}, i \in \{1, \dots, l_v\}$

RJEŠENJE: slovo = k

# Testiranje

- Za svaki  $j = 1, \dots, 5$  iz tenzora izoliramo  $j$ -tu perspektivu

$$\mathcal{A}(:, j, :)$$

→ slova  $\mathcal{A}(i, j, :)$ ,  $i = 1, \dots, 24$  su *testni primjeri*.

- Ostatak tenzora ( $\mathcal{A}(:, k, :)$ ,  $k \neq j$ ) je tretiran kao *training set*.
- 7 slova (A, L, H, P, R, U i Y), kojima se siluete međusobno značajno razlikuju

## 7 slova

Perspektiva	Grey-scale	Binary
Kut 1	6	5
Kut 2	7	7
Kut 3	7	7
Kut 4	7	7
Kut 5	7	5
Prosjek	6.8	6.2

**Tablica:** Točnost po perspektivi (7 slova)

Perspektiva	Grey-scale	Binary
A, L, R, U	5	5
H	3	3
P	5	4
Y	5	4

Tablica: Broj pogodaka po slovu (7 slova)

## 24 slova

Perspektiva	Grey-scale	Binary
Kut 1	10	11
Kut 2	14	13
Kut 3	17	16
Kut 4	13	11
Kut 5	13	14
Prosjeak	13.4	13

**Tablica:** Točnost po perspektivi (sva slova)

Perspektiva	Grey-scale	Binary
A, J, P	5	5
R, W, Y	4	4
D, K, S, Z	3	3
C, E, O, T, U	2	2
B, Q	1	1
H	0	0
F, I	2	1
G	5	4
V	0	1
X	3	4

Tablica: Broj pogodaka po slovu (sva slova)